

AI RAG 知识库开发与计算机后端开发核心手册

一、RAG 检索增强生成技术详解

1. RAG 定义

RAG (Retrieval-Augmented Generation, 检索增强生成), 是目前大模型落地最主流的技术方案。

在大模型生成回答之前, 先从私有本地文档、知识库中检索出相关的准确内容, 再交给大模型整理输出, 大幅解决大模型胡说八道、信息过时、无法读取私有数据的问题。

2. RAG 完整开发流程

- ① 文档加载: 读取 PDF、TXT 等本地私有文档
- ② 文本切片: 把长文档拆分成合适大小的文本块
- ③ 向量化: 把文本转为数字向量, 存入本地向量数据库
- ④ 相似度检索: 用户提问后, 匹配召回最相关的文档片段
- ⑤ 上下文拼接: 把检索到的内容+用户问题一起交给大模型
- ⑥ 生成回答: 大模型基于专属私有知识, 给出精准可靠的答案

3. 本项目技术栈

- 编程语言: Python
- 底层大模型: DeepSeek V4 Pro
- 向量数据库: FAISS (轻量高性能本地向量库)
- AI 辅助开发: Claude Code
- 后续扩展: 接入通义千问, 完成文档预处理、批量数据喂入

二、计算机后端开发&面试核心知识点

1. 计算机网络

TCP/IP 协议栈、三次握手四次挥手、HTTP/HTTPS 区别、状态码、跨域原理

2. 操作系统

进程线程区别、内存管理、调度算法、死锁产生条件与解决方案

3. 数据库

MySQL 索引原理、事务 ACID、隔离级别、慢查询优化

4. 开发基础

前后端分离架构、RESTful 接口规范、JSON 数据交互

三、项目个人总结

本项目独立完成轻量化私有化 RAG 私有知识库系统开发, 全程借助 AI 编码工具提升开发效率, 完成大模型 API 对接、向量检索、多文档问答全链路开发。

掌握大模型应用工程化落地、Prompt 工程、多模型协同开发能力, 具备 AI 赋能传统软件开发的实战经验。